

Dokument Embedding Manager

Technische Dokumentation

Version 0.1.0

Datum: 30.09.2026

Vollständig offline · 8-Service-Docker-Stack

Inhaltsverzeichnis

1. Überblick
2. Systemarchitektur
3. Installation
4. Erstkonfiguration
5. Ordnerverarbeitung
6. Jobüberwachung
7. Dokumente
8. Statistiken
9. Milvus
10. Export
11. HTTPS
12. Administration
13. Fehlerbehebung
14. Tests
15. Performance

1. Überblick

Der **Dokument Embedding Manager** ist eine vollständig offline betreibbare Webanwendung zum Einlesen, Konvertieren, Chunking, Einbetten und Durchsuchen von Dokumenten. Die Anwendung läuft in einer reproduzierbaren Docker-Umgebung aus acht getrennten Services und benötigt keine Internetverbindung: Dokumente, Modelle, Datenbank und Vektordatenbank verbleiben vollständig lokal.

Funktionsumfang

- Dokumentenscan eines Eingabeordners (rekursiv) mit SHA-256-Deduplizierung
- Upload einzelner Dokumente über die Weboberfläche
- Konvertierung von PDF, DOCX, DOC, ODT, RTF, PPTX, PPT, ODP, HTML, EPUB, XLSX, XLS, ODS, CSV, TXT, MD
- Chunking mit konfigurierbarer Überlappung, Token-Schätzung und Metadaten
- Vektorerzeugung mit Qwen3-Embedding-Modellen (0.6B, 4B, 8B)
- Vektorsuche über Milvus mit Cosinus-Ähnlichkeit
- Jobverwaltung mit Fortschritt, Tokens/s, CPU/RAM-Metriken, Pause, Resume, Cancel
- Statistiken, Export/Import (tar.zst) und selbstsignierte HTTPS-Zertifikate

2. Systemarchitektur




Abbildung 1 – Systemarchitektur

Serviceübersicht

Service	Technologie	Zweck
web	nginx	TLS-Terminierung (Port 8443 → 443), statische Assets
app	PHP-FPM	REST-API (30 Routen), Geschäftslogik
worker	PHP-CLI	asynchrone Job-/Dokumentenverarbeitung
db	MariaDB 11.4	Metadaten, Jobs, Dokumente, Chunks
milvus	Milvus 2.5.27 standalone	Vektorspeicher und Ähnlichkeitssuche
embedding	Qwen3 (Transformers)	Embedding-Inferenz
converter	Python + Pandoc + LibreOffice + Poppler	Dokument → Text/Markdown
migrate	PHP-CLI (one-shot)	Datenbankschema-Migration




Abbildung 2 – Datenfluss

Netzwerke: frontend (Bridge, nur web veröffentlicht Port 8443) und backend (internal: true). Sämtliche internen Dienste sind vom Hostnetz isoliert.

3. Installation

Voraussetzungen

- Docker Engine + Docker Compose v2
- git, bash, curl, jq (für Smoke-Test), openssl, tar
- ca. 20 GB freier Speicher (Modelle + Milvus-Daten)

Installation

```
git clone <repository> docvecwizard
cd docvecwizard
cp .env.example .env
# .env nach Bedarf anpassen
docker compose build
docker compose up -d
docker compose ps
```

Startvorgang verifizieren

```
curl -k https://localhost:8443/api/health
```

Die Anwendung ist anschließend unter `https://localhost:8443` erreichbar.

The screenshot displays the 'System' dashboard of the DocVec Embedding Manager. The interface is dark-themed with a sidebar on the left containing navigation links: Dashboard, Dokumente, Ordner, Aufträge, Suche, Kollektionen, Statistiken, Export / Import, TLS-Zertifikat, Einstellungen, and System (highlighted). The main content area is titled 'System' and includes a top bar with 'Aktualisieren' and a status indicator 'System bereit' at the bottom left.

System Overview:

- 0.1.0** App-Version
- 8.3.35** PHP
- Europe/Berlin** Zeitzone
- OK** Gesamtzustand

Dienste (Services):

Dienst	Status
Datenbank	OK
Embedding	OK
Converter	OK
Milvus	OK

Speicherpfade (Storage Paths):

```
{
  "input_root": "/srv/data/input",
  "staging_root": "/srv/data/staging",
  "export_root": "/srv/data/exports"
}
```

Embedding-Modelle (Embedding Models):

NAME	DIMENSION	MAX. TOKENS	METRIK	AKTIV
Qwen3-Embedding-0.6B	1.024	32.768	cosine	<button>Aktivieren</button>
Qwen3-Embedding-4B	2.560	32.768	cosine	<button>Aktivieren</button>
Qwen3-Embedding-8B	4.096	32.768	cosine	<button>Aktivieren</button>

System-Metriken (System Metrics):

SERVICE	METRIK	WERT	ZEITPUNKT
Keine Metriken.			

Abbildung 3 – Systemstatus nach dem Start

4. Erstkonfiguration

Nach dem ersten Start ist das Modell **Qwen3-Embedding-0.6B** aktiv (1024 Dimensionen). Über die Einstellungen lassen sich weitere Modelle (4B, 8B) aktivieren und die Verarbeitungsparameter anpassen.

The screenshot shows the DocVec Embedding Manager Dashboard. On the left is a sidebar with navigation links: Dashboard (selected), Dokumente, Ordner, Aufträge, Suche, Kollektionen, Statistiken, Export / Import, TLS-Zertifikat, Einstellungen, and System. The main area is titled 'Dashboard' and includes a 'Aktualisieren' button in the top right. It features eight summary cards: '910 Dokumente gesamt', '910 Verarbeitet', '0 Fehlgeschlagen', '0 Ausstehend', '10 Aufträge (0 laufen)', '910 Chunks', '33.676 Tokens (geschätzt)', and '0/3 Aktive Modelle'. Below these is a table titled 'Letzte Aufträge' with columns for NAME, QUELLE, MODELL, STATUS, DOKUMENTE, and ERSTELLT. The table lists five completed tasks, all using the 'Qwen3-Embedding-0.6B' model. At the bottom left, a status indicator shows 'System bereit' with a green dot.

NAME	QUELLE	MODELL	STATUS	DOKUMENTE	ERSTELLT
doc-format	fixtures	Qwen3-Embedding-0.6B	COMPLETED	1/1	30.9.2026, 22:41:26
all-formats	fixtures	Qwen3-Embedding-0.6B	COMPLETED	16/16	30.9.2026, 22:40:03
Smoke test 1790796181	smoke	Qwen3-Embedding-0.6B	COMPLETED	1/1	30.9.2026, 21:23:02
Graceful test 2	resume	Qwen3-Embedding-0.6B	COMPLETED	150/150	30.9.2026, 21:02:15
Graceful shutdown test	resume	Qwen3-Embedding-0.6B	COMPLETED	100/100	30.9.2026, 21:00:13

Abbildung 4 – Dashboard




Abbildung 5 – Einstellungen

Modellkonfiguration

Modell	Dimension	Max. Input	Distanz
Qwen3-Embedding-0.6B	1024	32768	Cosinus
Qwen3-Embedding-4B	2560	32768	Cosinus
Qwen3-Embedding-8B	4096	32768	Cosinus

Jedes Modell nutzt eine eigene Milvus-Collection (`docvec_<modell>`). Beim Wechsel prüft das System die Dimensionskompatibilität.

5. Ordnerverarbeitung

Ein Job verarbeitet einen Quellordner aus `data/input`. Optional wird rekursiv gescannt. Die Dateien werden dedupliziert, konvertiert, in Chunks zerlegt, eingebettet und nach Milvus geschrieben.




Abbildung 6 – Ordnerauswahl und Upload




Abbildung 7 – Dokumentenverarbeitungs-Pipeline

Unterstützte Formate

pdf, docx, doc, odt, rtf, pptx, ppt, odp, html, htm, epub, xlsx, xls, ods, csv, txt, md, markdown

6. Jobüberwachung

DocVec
Embedding Manager

Dashboard

Dokumente

Ordner

Aufträge

Suche

Kollektionen

Statistiken

Export / Import

TLS-Zertifikat

Einstellungen

System

● System bereit

Aufträge

Neuer Auftrag

NAME	QUELLE	MODELL	STATUS	DOKUMENTE	ERSTELLT
doc-format	fixtures	Qwen3-Embedding-0.6B	COMPLETED	1/1	30.9.2026, 22:41:26
all-formats	fixtures	Qwen3-Embedding-0.6B	COMPLETED	16/16	30.9.2026, 22:40:03
Smoke test 1790796181	smoke	Qwen3-Embedding-0.6B	COMPLETED	1/1	30.9.2026, 21:23:02
Graceful test 2	resume	Qwen3-Embedding-0.6B	COMPLETED	150/150	30.9.2026, 21:02:15
Graceful shutdown test	resume	Qwen3-Embedding-0.6B	COMPLETED	100/100	30.9.2026, 21:00:13
Crash recovery round 2	resume	Qwen3-Embedding-0.6B	COMPLETED	300/300	30.9.2026, 20:58:17
Crash recovery test	resume	Qwen3-Embedding-0.6B	COMPLETED	300/300	30.9.2026, 20:56:27
Resume test	resume	Qwen3-Embedding-0.6B	COMPLETED	40/40	30.9.2026, 20:55:53
Smoke test 1790794519	smoke	Qwen3-Embedding-0.6B	COMPLETED	1/1	30.9.2026, 20:55:20
Smoke test 1790794459	smoke	Qwen3-Embedding-0.6B	COMPLETED	1/1	30.9.2026, 20:54:19

Abbildung 8 – Jobfortschritt während der Embedding-Verarbeitung




Abbildung 9 – Job-Lebenszyklus

Während der Verarbeitung werden Fortschritt, Tokens/s, CPU- und RAM-Nutzung sowie der Dokumentstatus (DISCOVERED/PROCESSING/COMPLETED/FAILED) live angezeigt. Abgebrochene Läufe werden beim Neustart automatisch wieder aufgenommen (Crash-Recovery).

7. Dokumente

DocVec Embedding Manager Dashboard Dokumente Ordner Aufträge Suche Kollektionen Statistiken Export / Import TLS-Zertifikat Einstellungen System System bereit	Dokumente Aktualisieren						
	Nach Dateiname/Pfad filtern...						
	DATEI	PFAD	STATUS	CHUNKS	GRÖSSE	MODELL	
	smoke-1790796181.txt	smoke-1790796181.txt	COMPLETED	1	163 B	Qwen3-Embedding-0.6B	Löschen
	doc-150.txt	doc-150.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen
	doc-149.txt	doc-149.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen
	doc-148.txt	doc-148.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen
	doc-147.txt	doc-147.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen
	doc-146.txt	doc-146.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen
	doc-145.txt	doc-145.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen
	doc-144.txt	doc-144.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen
	doc-143.txt	doc-143.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen
	doc-142.txt	doc-142.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen
	doc-141.txt	doc-141.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen
	doc-140.txt	doc-140.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen
	doc-139.txt	doc-139.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen
	doc-138.txt	doc-138.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen
	doc-137.txt	doc-137.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen
	doc-136.txt	doc-136.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen
	doc-135.txt	doc-135.txt	COMPLETED	1	94 B	Qwen3-Embedding-0.6B	Löschen

Abbildung 10 – Dokumentliste mit Verarbeitungsstatus




Abbildung 11 – Vektorsuche

Jedes Dokument führt Metadaten wie Dateigröße, SHA-256-Hash, Seitenzahl, Zeichen-/Wortzahl, Token-Schätzung und Chunk-Anzahl. Die Suche führt eine Cosinus-Ähnlichkeitssuche über Milvus aus.

8. Statistiken




Abbildung 12 – Statistikübersicht

Auswertungen zu Dokumentalter, Dateitypen, Seiten, Tokens und Speicherbedarf werden aus der Datenbank aggregiert.

9. Milvus




Abbildung 13 – Milvus-Collections




Abbildung 14 – Milvus-Struktur

Pro aktivem Modell existiert eine eigene Collection. Das Schema besteht aus `document_id` (Primärschlüssel), `chunk_index` und `vector` (FloatVector). Index: AUTOINDEX mit Metrik COSINE.

10. Export

DATEI	GRÖSSE	ERSTELLT	
b571c68e-5fcc-45a4-9dd3-a46ed22bc728.tar.gz	75.4 KB	30.9.2026, 21:23:06	Download
25f3de78-992b-452a-a8cd-48f81f08664d.tar.gz	3.7 KB	30.9.2026, 20:55:24	Download
e15f9b08-bb15-4b4a-bae9-2720eef5bcbe.tar.gz	3.6 KB	30.9.2026, 20:54:32	Download
05bfac0b-6244-445d-a418-3404275c9242.tar.gz	825 B	30.9.2026, 22:31:14	Download

Abbildung 15 – Exportdialog




Abbildung 16 – Export-/Importprozess

Der Export erzeugt ein einzelnes `tar.zst`-Archiv (Zstandard) mit Dokumenten, Chunks, Vektoren und Manifest inkl. SHA-256-Prüfsumme. Der Import stellt den vollständigen Bestand offline wieder her.

11. HTTPS




Abbildung 17 – Zertifikatsverwaltung




Abbildung 18 – HTTPS-/Zertifikatsworkflow

Über `/api/tls/selfsigned` wird ein selbstsigniertes Zertifikat mit eigener CA erzeugt (SAN: `localhost`). `/api/tls/{id}/activate` aktiviert es; nginx wird neu geladen. Alternativ können CSR erzeugt oder Zertifikate importiert werden.

12. Administration




Abbildung 19 – Datenbankschema

Häufige Befehle

```
docker compose ps          # Status aller Services
docker compose logs -f worker # Worker-Logs verfolgen
docker compose logs -f app   # API-Logs verfolgen
docker compose restart worker # Worker neu starten
./scripts/status.sh          # Gesamtstatus
./scripts/check-health.sh    # Health-Checks
```

Backup

```
./scripts/backup-db.sh      # MariaDB-Dump
./scripts/backup-milvus.sh  # Milvus-Volumen sichern
```

Das Schema liegt zusätzlich als `database/schema.sql` und `database/migrations/0001_initial.sql` bei.

13. Fehlerbehebung

Symptom	Ursache / Lösung
Zugriff verweigert (MariaDB)	.env vor erstem Start korrekt setzen; MARIADB_* wird nur bei Erstinitialisierung gelesen
Worker-Crashloop	docker compose logs worker prüfen; leere .env vermeiden
Embedding-Modell fehlt	Modelle werden beim Start des embedding-Service geladen; Logs prüfen
Zertifikatswarnung	Selbstsigniertes Zertifikat erwartet; im Browser Ausnahme bestätigen
Documents bleiben PROCESSING	Worker neu starten; Crash-Recovery setzt Stale-Zustände zurück

14. Tests

Die Testsuite umfasst Unit-, Integrations- und Smoke-Tests.

```
php tests/unit/run.php      # Unit-Tests
tests/integration/run.sh    # Integrations-Tests (im Container)
tests/smoke-test.sh         # Smoke-Test (35 Prüfungen)
```

Ergebnisse

Test	Erwartetes Ergebnis	Tatsächliches Ergebnis	Status
Unit-Tests	alle Tests grün	37/37 bestanden	PASS
Integrations-Tests	alle Tests grün	10/10 bestanden	PASS
Smoke-Test	35 Prüfungen grün	35/35 bestanden	PASS

15. Performance

Die folgenden Werte wurden in der lokalen Referenzumgebung gemessen.

Kennzahl	Wert
Embedding-Durchsatz	ca. 18,4 Tokens/s (0.6B, CPU)
Dokumente im Testlauf	909 COMPLETED
Jobs im Testlauf	9 COMPLETED
Chunk-Konfiguration	512 Tokens, 64 Überlappung, Limit 1024
Vektordimensionen	1024 / 2560 / 4096

Die tatsächliche Performance hängt stark von CPU, verfügbarem RAM und dem gewählten Modell ab. Größere Modelle (4B, 8B) erhöhen die Qualität, senken aber den Durchsatz.